

AGUSTÍN HERRERA

+56 9 6844 1857 | aiherrera1@uc.cl | LinkedIn | Santiago, Chile (Disponible para reubicación)

RESUMEN PROFESIONAL

Ingeniero en Ciencias de la Computación (Pontificia Universidad Católica de Chile) con más de 2 años de experiencia profesional diseñando y operando sistemas distribuidos escalables en AWS. Historial comprobado construyendo pipelines de inferencia ML, flujos de orquestación de múltiples pasos (Step Functions, SQS, ECS), aplicaciones de IA multi-agente y sistemas full-stack con frameworks modernos de TypeScript/JavaScript. Apasionado por la IA generativa y con entusiasmo por aprovechar los LLMs para potenciar experiencias creativas dinámicas y personalizadas a gran escala.

EXPERIENCIA PROFESIONAL

Ingeniero DevOps / Desarrollo de Software

diio

Dic 2024 – Presente

Santiago, Chile

- Diseño e implementó un **pipeline de inferencia ML de extremo a extremo para transcripción de audio y diarización de hablantes**, orquestando **AWS Step Functions, Lambda, SQS, ECS y S3**; reemplazó a un proveedor externo y **redujo costos en un 60%** mejorando al mismo tiempo el rendimiento y la confiabilidad.
- Construyó **Spark**, un asistente de ventas de IA multi-agente impulsado por **Google Vertex AI Reasoning Engine** (patrón de bucle de agente: planificar → llamada a herramienta → resultado → continuar razonamiento). Implementó el **servidor MCP en Ruby on Rails** exponiendo 6 herramientas — RAG sobre Elasticsearch, generación de consultas texto-a-DSL, integraciones CRM y generación de gráficos — mientras el razonamiento del LLM se ejecuta externamente en Google Cloud. Demostró una clara separación de responsabilidades: Google gestiona el “**cuándo llamar**”, Rails gestiona el “**cómo ejecutar**”.
- Diseñó el **pipeline RAG** para Spark: genera embeddings de consultas mediante **OpenAI text-embedding-3-large**, ejecuta búsqueda híbrida **BM25 + KNN vectorial** en Elasticsearch, y retorna fragmentos de conversación ordenados por relevancia (hasta 35 conversaciones, limitados a 100K tokens) con bloques de contexto XML enriquecidos para que el LLM sintetice respuestas.
- Implementó **auto-escalado dinámico de workers ECS Sidekiq** mediante **alarmas de CloudWatch** activadas por métricas de profundidad de cola en tiempo real, reduciendo costos de cómputo sin sacrificar el rendimiento.
- Diseño e implementó un **stack de observabilidad** con **CloudWatch, Prometheus y Grafana** (alojado en EC2), exponiendo métricas clave de negocio e infraestructura y habilitando la detección proactiva de incidentes en el entorno de producción.
- Migró la base de datos de producción de **RDS PostgreSQL a Citus distribuido**, habilitando escalado horizontal y mejorando el rendimiento de consultas analíticas en un **10%**.
- Optimizó los **pipelines de CI/CD con GitHub Actions**, reduciendo el tiempo de despliegue en un **50%** mediante paralelización, caché de builds y builds en matriz.
- Construyó un **pipeline nocturno de análisis de seguridad impulsado por IA** sobre hardware **NVIDIA Jetson** en las instalaciones, que abre automáticamente **Pull Requests con correcciones de vulnerabilidades generadas por LLM y sus justificaciones**.

Desarrollo de Software

Lolocar.com

Ago 2023 – Dic 2023

Santiago, Chile

- Desarrolló **APIs RESTful** escalables para el cálculo de cargos de peaje de arrendatarios, integradas con sistemas backend existentes utilizando **Ruby on Rails**.
- Diseño e implementó **paneles de administración internos** para la gestión de datos en tiempo real, mejorando la eficiencia operativa del equipo de operaciones.
- Lideró el despliegue de la aplicación en **Google Cloud Platform**, mejorando la confiabilidad y velocidad de despliegue en un **20%**.

EDUCACIÓN

Pontificia Universidad Católica de Chile

Ingeniería en Ciencias de la Computación

Mar 2020 – Dic 2024

Santiago, Chile

- Especialidad:** Ingeniería de Software | **Minor:** Fundamentos Científicos y Tecnológicos de la Computación

HABILIDADES TÉCNICAS

Lenguajes:

Nube e Infraestructura:

IA / ML y Agentes:

Observabilidad:

Backend y Frameworks:

Bases de Datos y Búsqueda:

CI/CD y DevOps:

Idiomas:

Python, TypeScript / JavaScript, Go, Ruby, Java, C / C++, C#, Bash, R

AWS (EC2, ECS, ECR, S3, IAM, Lambda, Step Functions, SQS, CloudWatch, RDS), Docker, GCP

Sistemas multi-agente (Vertex AI Reasoning Engine), automatización con LLMs, pipelines RAG, embeddings de OpenAI, búsqueda vectorial híbrida (BM25 + KNN), integración de IA generativa

CloudWatch, Prometheus, Grafana, auto-escalado de ECS con alarmas de CloudWatch

Ruby on Rails, Nest.js, Next.js, React, Vue, Svelte, Angular

PostgreSQL, Citus (distribuido), Redis, Elasticsearch, SQL

GitHub Actions, scripting en Bash, Linux

Español (Nativo), Inglés (C2 – Competente)